


SRAG Insight Agent — arquitetura da solução

Agente orquestrador em LangGraph que combina métricas do Open DATASUS (SIVEP-Gripe) e notícias em tempo real para gerar relatórios auditáveis sobre SRAG.



Fluxo de uma execução, guardrails e governança

Como o agente produz um relatório e quais controles atuam em cada etapa. Todos os eventos ficam na trilha de auditoria da execução.

Fluxo de uma execução

- Pedido:** o usuário informa a UF (ou Brasil) e, opcionalmente, um foco. Os guardrails de entrada validam o pedido antes de qualquer chamada ao LLM.
- Orquestração:** o LLM recebe as três tools e decide quais chamar (normalmente as três, em paralelo). Os argumentos são uma enumeração fechada de UFs: o LLM não escreve SQL nem consultas de busca.
- Execução das tools:** métricas e séries vêm de SQL fixo no DuckDB somente leitura; notícias passam por triagem anti-injeção e mascaramento de PII. Tudo fica no `RunContext`.
- Cobertura:** se o LLM não chamou alguma tool obrigatória ou estourou o limite de passos, o grafo a executa de forma determinística e registra o motivo.
- Redação:** o LLM escreve a análise em formato estruturado (Pydantic), a partir das métricas, das séries e das notícias, que chegam marcadas como conteúdo não confiável.
- Validação:** percentuais e contagens precisam bater com os dados; citações de notícias precisam existir; o texto não pode conter instruções nem dados pessoais. Se reprovar, o LLM recebe o motivo e reescreve (até 2 tentativas); persistindo, o relatório sai com aviso explícito.
- Relatório:** tabela de métricas, gráficos e lista de fontes são montados a partir dos dados; o LLM contribui apenas com os textos interpretativos.

Métricas (definições e limitações)

Métrica	Cálculo	Limitação
Aumento de casos	casos dos últimos 7 dias completos vs. 7 dias anteriores	semana mais recente pode ser revisada
Mortalidade	óbitos por SRAG ÷ casos com desfecho (90 dias)	letalidade entre casos, não mortalidade populacional
Ocupação de UTI	internados em UTI ÷ hospitalizados (30 dias)	proxy: a base não tem nº de leitos
Vacinação	vacinados (COVID-19) ÷ casos com informação (30 dias)	só pessoas com SRAG, não a população

Camadas de guardrails

Camada	Controle
Entrada	UF em lista fechada; foco ≤ 300 caracteres, restrito ao tema, sem padrões de injeção nem dados pessoais.
Dados	Banco aberto em modo somente leitura; consultas SQL fixas e parametrizadas; LLM sem acesso a SQL.
Tools	Schema estrito; tool desconhecida ou argumento inválido vira erro devolvido ao LLM; limite de passos do orquestrador.
Conteúdo externo	Notícias com padrões de injeção são descartadas; PII mascarada; texto entregue ao LLM como não confiável.
Saída	Percentuais e contagens conferidos com os dados; ids de notícias verificados; detecção de instruções; mascaramento de PII; revisão automática.
Resiliência	Modelo reserva quando o principal está sobrecarregado (Gemini) ou recusa a requisição (Claude); falha das notícias não derruba o relatório.

Dados sensíveis

- O ETL lê só 21 das 194 colunas (allowlist documentada no código).
- Removidos antes de gravar: nº da notificação, data de nascimento, município, unidade de saúde, ocupação, lotes de vacina e todos os campos de texto livre.
- Idade exata vira faixa etária; localização fica restrita à UF.
- O LLM só recebe agregados (contagens e proporções), nunca registros individuais.
- Dados brutos, banco, logs e `.env` ficam fora do Git.

Governança e transparência

- Trilha de auditoria JSONL por execução, com sequência e horário de cada evento.
- Cada métrica traz numerador, denominador, período, definição e limitações.
- Prompts versionados no código; hash do prompt registrado a cada chamada.
- O relatório informa modelo usado, data de corte, data de referência e id da execução.